Министерство образования Республики Беларусь

Учреждение образования

«Брестский Государственный технический университет»

Кафедра ИИТ

Лабораторная работа №2

По дисциплине «Интеллектуальный анализ данных»

Тема: «Автоэнкодеры»

Выполнил:

Студент 4 курса

Группы ИИ-25

Кулик Я. А.

Проверил:

Андренко К. В.

Брест 2026

Цель работы: научиться применять автоэнкодеры для осуществления визуализации данных и их анализа.

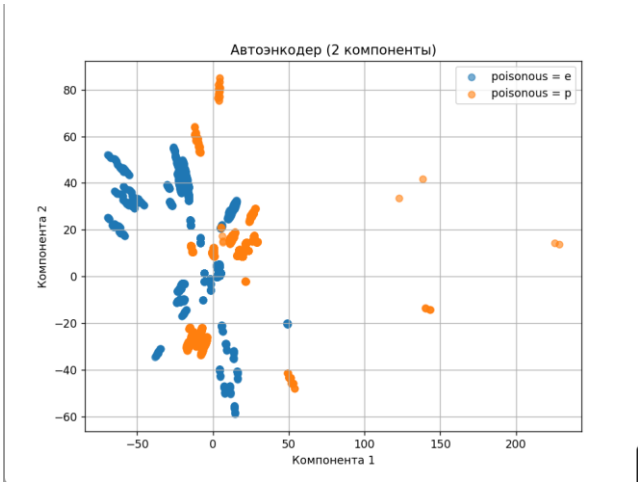
Вариант 7

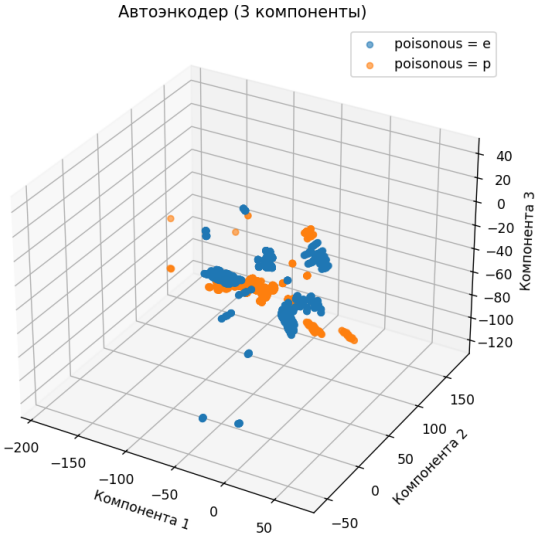
№ варианта	Выборка	Класс
7	Mushroom	poisonous

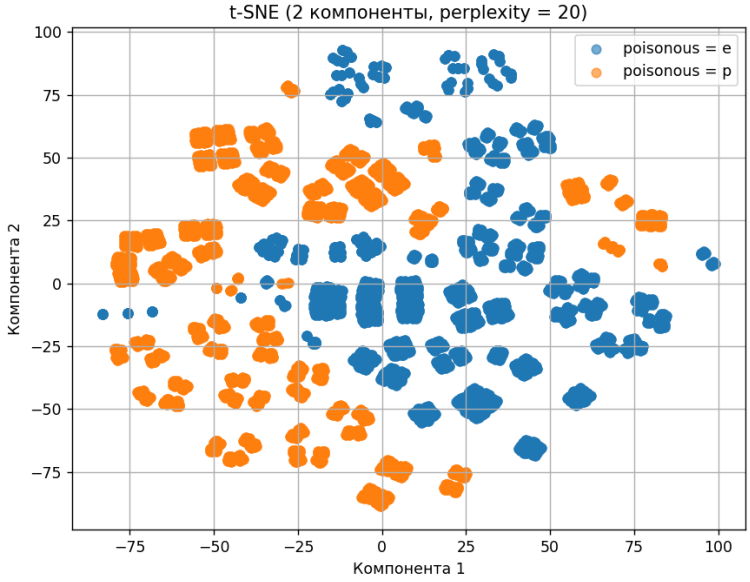
Задание:

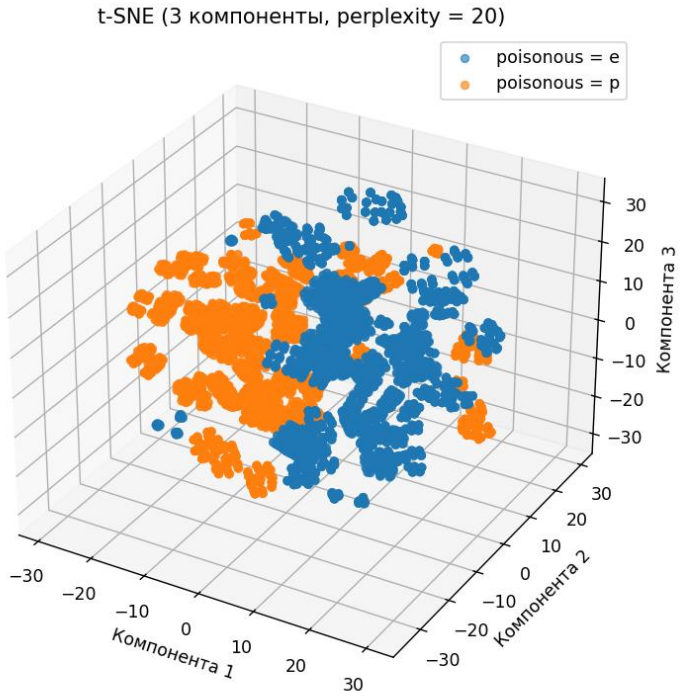
1. Используя выборку по варианту, осуществить проецирование данных на плоскость первых двух и трех главных компонент с использованием нейросетевой модели автоэнкодера (с двумя и тремя нейронами в среднем слое);
2. Выполнить визуализацию полученных главных компонент с использованием средств библиотеки matplotlib, обозначая экземпляры разных классов с использованием разных цветовых маркеров;
3. Реализовать метод t-SNE для визуализации данных (использовать также 2 и 3 компонента), построить соответствующую визуализацию;
4. Применить к данным метод PCA (2 и 3 компонента), реализованный в ЛР №1, сделать выводы;

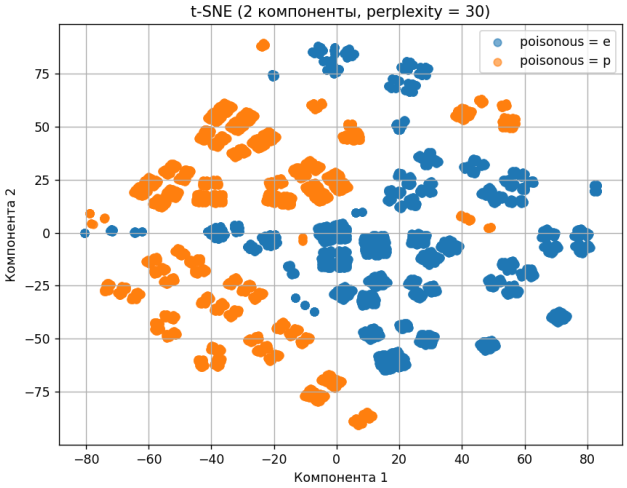
Результат:



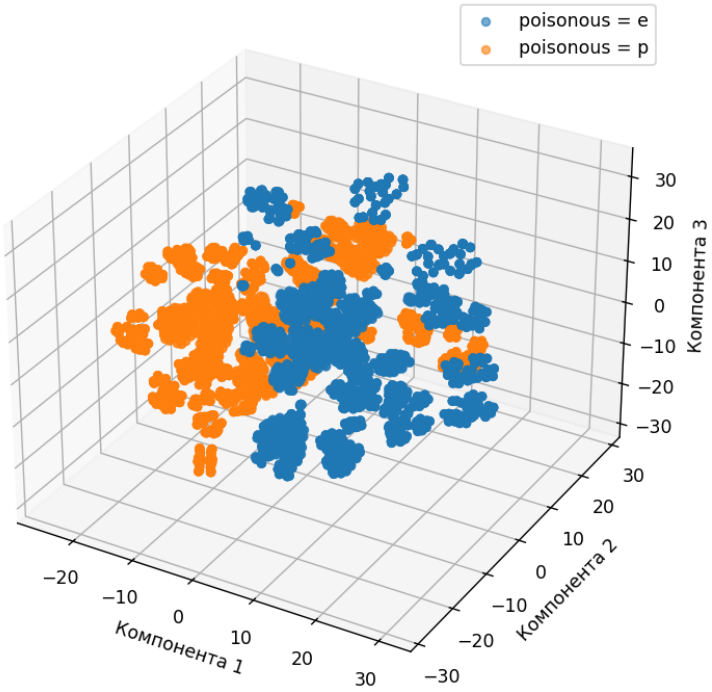



t-SNE (2 компоненты, perplexity = 20)
poisonous = e
poisonous = p
Компонента 2
Компонента 1
100
75
50
25
0
−25
−50
−75
−75
−50
−25
0
25
50
75
100

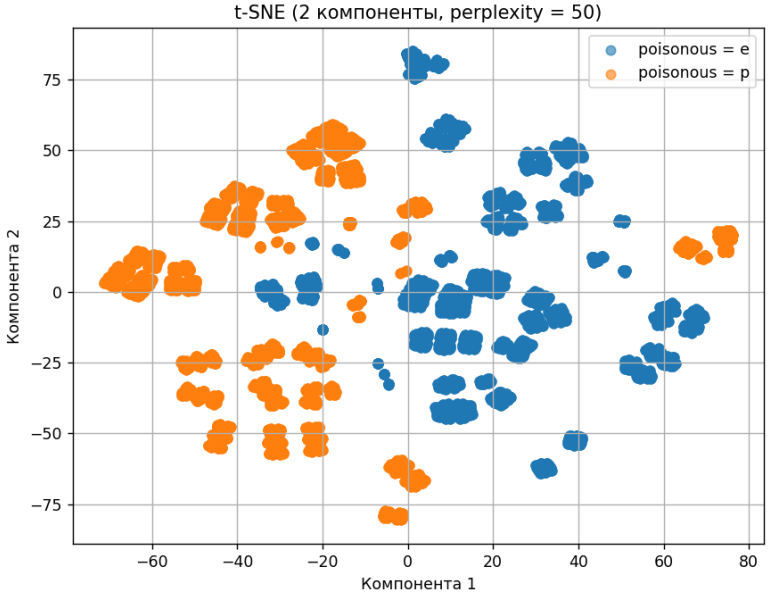

t-SNE (3 компоненты, perplexity = 20)
poisonous = e
poisonous = p
Компонента 1
Компонента 2
Компонента 3
−30
−20
−10
0
10
20
30


t-SNE (2 компоненты, perplexity = 30)
poisonous = e
poisonous = p
Компонента 2
Компонента 1
75
50
25
0
−25
−50
−75
−80
−60
−40
−20
0
20
40
60
80

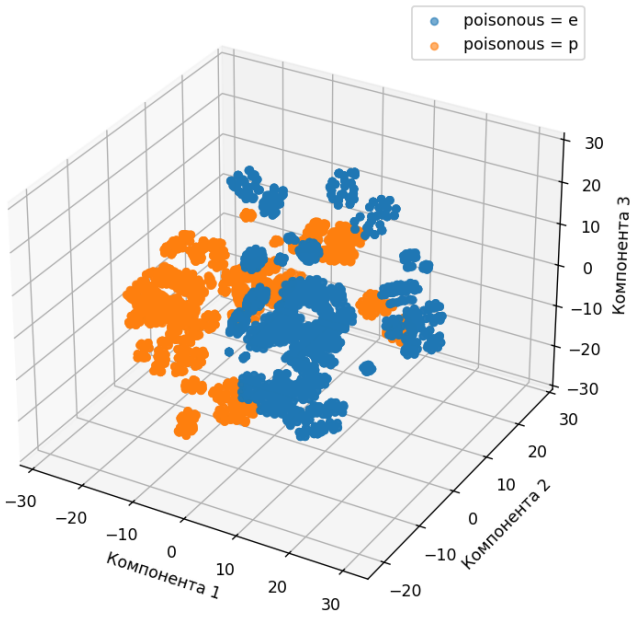
t-SNE (3 компоненты, perplexity = 30)



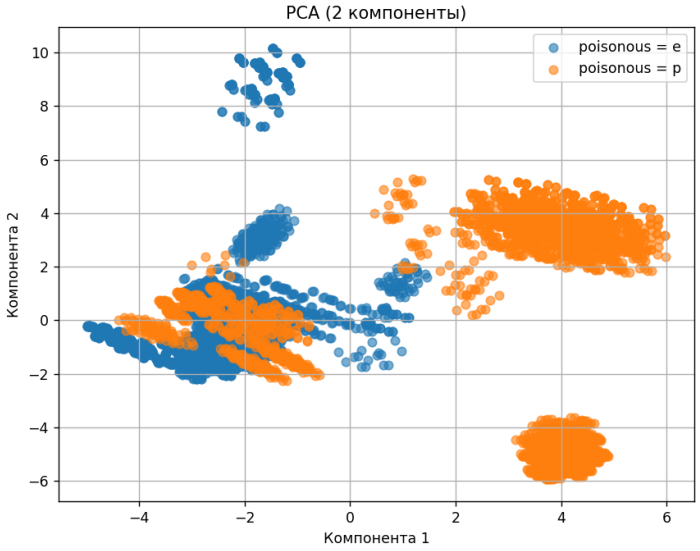
t-SNE (2 компоненты, perplexity = 50)

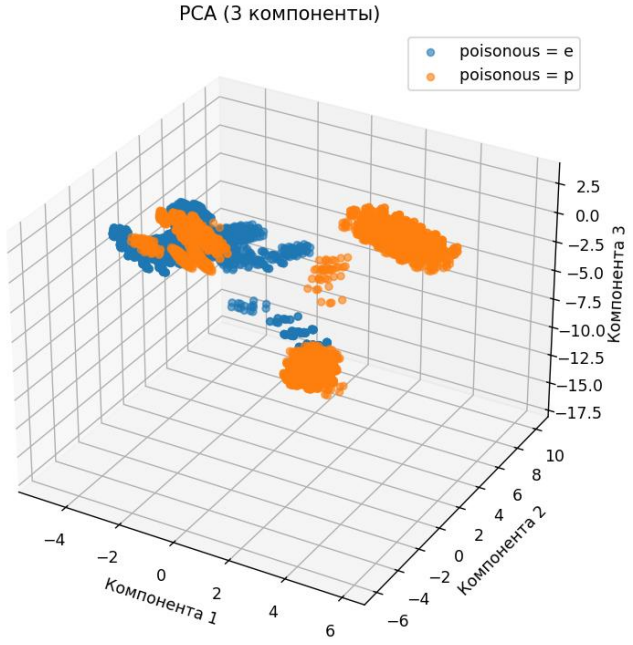


t-SNE (3 компоненты, perplexity = 50)



Была построена нейросетевая модель автоэнкодера с двумя и тремя нейронами в среднем слое. Проекция данных показала, что съедобные и ядовитые грибы разделяются лишь частично: в центре проекции классы перекрываются, а отдельные объекты оказались далеко от основной массы. Это связано с тем, что около 117 признаков после one-hot кодирования сжимаются всего до двух-трёх компонент, и часть информации о различиях между классами теряется. Метод t-SNE, напротив, сохраняет локальные соседства объектов и даёт чёткие, отдельные кластеры обоих классов.





Метод t-SNE был применён для визуализации данных в 2 и 3 компонентах при значениях perplexity = 20, 30, 50 и инициализации через PCA. Классы poisonous образуют отдельные компактные кластеры, и между съедобными и ядовитыми грибами видно чёткое разделение. При perplexity = 20 кластеры раздроблены на множество мелких групп, а наиболее чёткая картина получена при perplexity = 50. В 3D-визуализации кластеры тоже различимы, но на отдельных ракурсах частично накладываются друг на друга.
Метод главных компонент был применён к данным для 2 и 3 компонент. На графиках видно, что PCA разделяет классы лишь частично: несколько групп ядовитых и съедобных грибов выделяются отдельно, но основная масса объектов обоих классов перекрывается, так как линейное проецирование не позволяет сохранить структуру данных после one-hot кодирования. Все три метода показали, что классы poisonous в целом различимы в пространстве малой размерности, однако степень разделения разная. Наиболее чётко классы разделил t-SNE, поскольку он сохраняет локальные соседства объектов. Автоэнкодер и PCA дали частичное

разделение с заметным перекрытием классов, что связано с сильным сжатием около 117 признаков до двух-трёх компонент.

Вывод: в данной лабораторной работе я научилась применять автоэнкодеры для осуществления визуализации данных и их анализа.