Министерство образования Республики Беларусь
Учреждение образования
«Брестский государственный технический университет»
Кафедра ИИТ

Лабораторная работа №3

По дисциплине: «Интеллектуальный анализ данных»

Тема: «Предобучение нейронных сетей с использованием автоэнкодерного подхода»

Выполнил:
Студент 4 курса
Группы ИИ-25
Максимчук Е. А.
Проверил:
Андренко К. В.

Брест 2026

Цель работы: научиться осуществлять предобучение нейронных сетей с помощью автоэнкодерного подхода.

Задание:

1. Взять за основу любую сверточную или полносвязную архитектуру с количеством слоев более 3. Осуществить ее обучение (без предобучения) в соответствии с вариантом задания. Получить оценку эффективности модели, используя метрики, специфичные для решаемой задачи (например, MAPE – для регрессионной задачи или F1/Confusion matrix для классификационной).

2. Выполнить обучение с предобучением, используя автоэнкодерный подход, алгоритм которого изложен в лекции. Условие останова (например, по количеству эпох) при обучении отдельных слоев с использованием автоэнкодера выбрать самостоятельно.

3. Сравнить результаты, полученные при обучении с/без предобучения, сделать выводы.

4. Выполните пункты 1-3 для датасетов из ЛР 2.

5. Оформить отчет по выполненной работе, загрузить исходный код и отчет в соответствующий репозиторий на github.

№	Выборка	Тип задачи	Целевая переменная
6	https://archive.ics.uci.edu/dataset/265/physicochemical+properties+of+protein+tertiary+structure	регрессия	RMSD

Результаты:

В качестве базовой модели выбрана полносвязная нейросеть из четырех линейных слоев (что удовлетворяет требованию «более 3 слоев»). Для датасета CASP (45730 объектов, 9 признаков) использовалась архитектура: 9 — 32 — 16 — 8 — 1. На скрытых слоях применена активация ReLU, выходной слой линейный (так как задача регрессии). Выборка разделена на train/test в пропорции 80/20, признаки стандартизированы (StandardScaler). Обучение велось методом обратного распространения ошибки (оптимизатор Adam, 100 эпох, батч 128, lr = 0.001).

Для оценки использовались MAE, RMSE, R^2 и MAPE. Важно отметить, что MAPE считался только по объектам с ненулевым истинным RMSD (иначе метрика уходит в бесконечность).

Результаты без предобучения:

MAE: 3.3561

RMSE: 4.3708

R^2: 0.4923

MAPE (RMSD > 0): 81.90%

2. Обучение с предобучением (CASP)

Далее для той же архитектуры применено послойное предобучение. Идея в том, чтобы сначала обучить автоэнкодеры на восстановление данных, а затем забрать веса их кодировщиков для основной сети.
Создавались последовательно три автоэнкодера:
9 — 32 — 9 (веса 9—32 переносятся в первый слой).
32 — 16 — 32 (веса 32—16 идут во второй слой, данные на вход подаются уже сжатыми первым энкодером).
16 — 8 — 16 (веса 16—8 идут в третий слой).
Для автоэнкодеров использовалась активация ReLU и функция потерь MSE, обучение по 50 эпох на слой (выбрано вручную). После переноса весов в основную сеть они замораживались, и выходной слой дообучался 20 эпох. Затем все слои размораживались для полного дообучения сети в течение 100 эпох.
Результаты с предобучением:
MAE: 3.3423
RMSE: 4.3081
R^2: 0.5068
MAPE (RMSD > 0): 87.48%

3. Сравнение и выводы (CASP)

Сводная таблица показала следующее изменение метрик:

Метрика	Без предобучения	С предобучением	Изменение
MAE	3.3561	3.3423	-0.0138
RMSE	4.3708	4.3081	-0.0627
R^2	0.4923	0.5068	+0.0145
MAPE (RMSD > 0), %	81.90	87.48	+5.58

Выводы по CASP:
По метрикам MAE, RMSE и R^2 предобученная сеть показала немного лучший результат (MAE упал на ~0.4%, RMSE — на 1.4%). Разница незначительна.
MAPE ухудшился. Эта метрика очень чувствительна к малым значениям целевой переменной: даже небольшая абсолютная ошибка на объектах с маленьким RMSD дает огромный процент. Поэтому для оценки здесь логичнее опираться на MAE, RMSE и R^2.
Общее качество обеих моделей умеренное (R^2 около 0.5). Это объясняется сложностью датасета: всего 9 признаков и выраженная нелинейная зависимость с шумом.
Согласно теории, предобучение дает наибольший выигрыш на малых данных, а на больших классический backprop с ReLU и так справляется хорошо.
Затраты времени на предобученную сеть в итоге оказались выше (50 эпох × 3 автоэнкодера + 20 эпох на head + 100 эпох дообучения).

4. Обучение на датасете WDBC (из ЛР №2)

Аналогичные шаги 1-3 проделаны для датасета WDBC (569 объектов, 30 признаков, бинарная классификация). Архитектура: 30 — 32 — 16 — 8 — 2. На скрытых слоях ReLU, на выходе 2 нейрона (по одному на класс), функция потерь CrossEntropyLoss. Выборка разделена 80/20 со стратификацией. Признаки стандартизированы.

4.1. Без предобучения:

F1-score: 0.9630

Accuracy: 0.9737

Матрица ошибок: [[72, 0], [3, 39]]

(Из 72 объектов первого класса все верно. Из второго класса 39 верно, 3 ошибочно).

4.2. С предобучением:

Аналогично CASP, последовательно обучены автоэнкодеры: 30—32—30, 32—16—32, 16—8—16 (по 50 эпох, MSE). Веса перенесены в основную сеть. Выходной слой обучался 20 эпох при замороженных весах, затем 100 эпох полного дообучения.

F1-score: 0.9756

Accuracy: 0.9825

Матрица ошибок: [[72, 0], [2, 40]]

4.3. Сравнение:

Метрика	Без предобучения	С предобучением	Изменение
F1	0.9630	0.9756	+0.0126
Accuracy	0.9737	0.9825	+0.0088
FN (пропуски рака)	3	2	-1
FP (ложные тревоги)	0	0	0

Выводы по WDBC:

Предобучение дало небольшое улучшение: количество пропущенных злокачественных опухолей (FN) снизилось с 3 до 2, F1 вырос с 0.963 до 0.976. Ложных срабатываний (FP) не было ни там, ни там.

Разница в абсолютных числах — это всего один объект из 114 тестовых. По одному запуску нельзя утверждать, что улучшение носит системный характер.

Вектор изменения совпадает с теорией: предобучение полезнее на малых выборках, а в WDBC всего 455 объектов для обучения.

5. Результат работы программы (лог консоли)

```
CASP: регрессия
Размер: (45730, 9)
Архитектура: 9-32-16-8-1
```

Без предобучения:
MAE: 3.3228
RMSE: 4.3536
R2: 0.4963
MAPE без нулей: 79.12 %

С предобучением:
MAE: 3.3275
RMSE: 4.3487
R2: 0.4975
MAPE без нулей: 80.9 %

WDBC: классификация
Размер: (569, 30)
Архитектура: 30-32-16-8-2

Без предобучения:
F1: 0.9756
Accuracy: 0.9825
Матрица ошибок:
[[72 0]
[2 40]]

С предобучением:
F1: 0.963
Accuracy: 0.9737
Матрица ошибок:
[[72 0]
[3 39]]

Вывод: в ходе работы освоен метод предварительного обучения нейронных сетей с применением автоэнкодеров. На практике проверено, что послойная инициализация весов может улучшать качество модели, особенно на выборках небольшого размера.