Министерство образования Республики Беларусь

Учреждение образования

«Брестский Государственный технический университет»

Кафедра ИИТ

Лабораторная работа №1

По дисциплине «Интеллектуальный анализ данных»

Тема: «PCA»

Выполнил:

Студент 4 курса

Группы ИИ-25

Мохорева Т. Д.

Проверил:

Андренко К. В.

Брест 2026

Цель: научиться применять метод PCA для осуществления визуализации данных

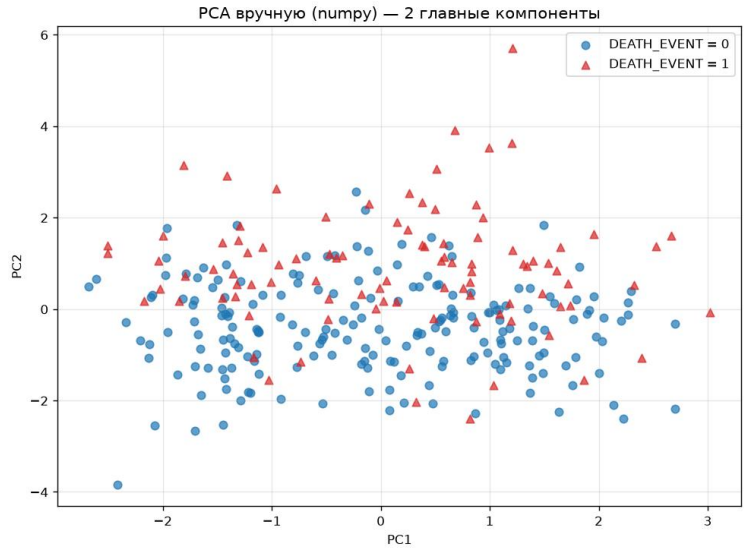
Вариант 9

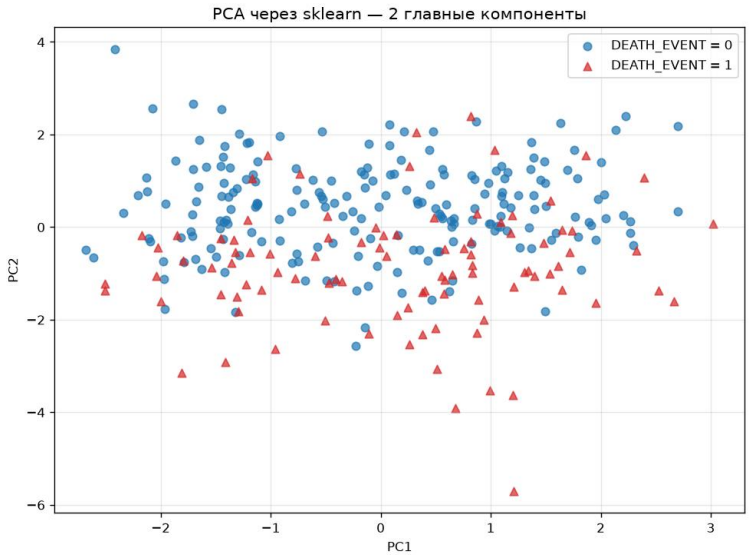
№ варианта	Выборка	Класс
9	heart+failure+clinical+records.zip	death_event

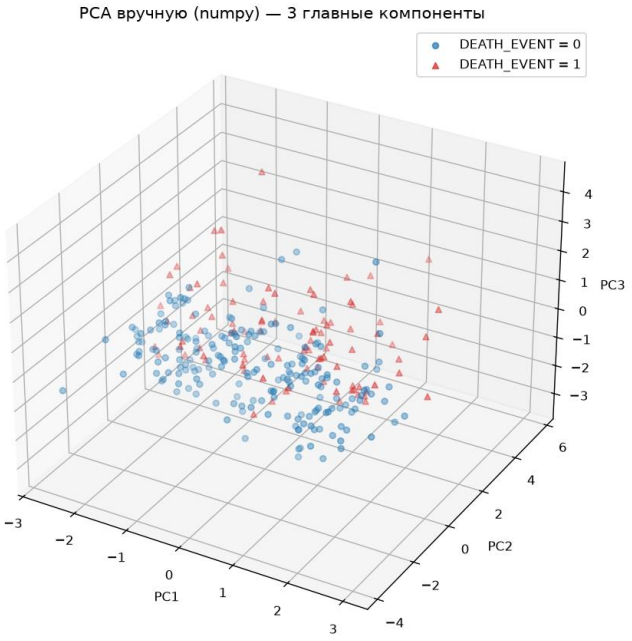
Задание:

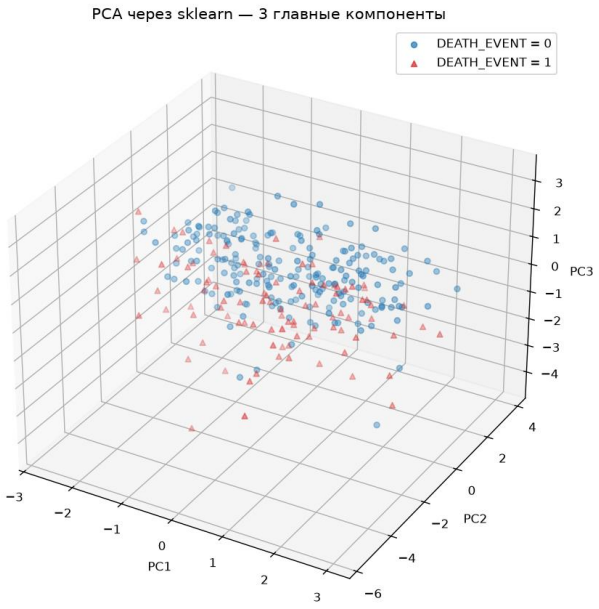
1. Используя выборку по варианту, осуществить проецирование данных на плоскость первых двух и трех главных компонент (двумя способами: 1. вручную через использование numpy.linalg.eig для вычисления собственных значений и собственных векторов и 2. с помощью sklearn.decomposition.PCA для непосредственного применения метода PCA – два независимых варианта решения);
2. Выполнить визуализацию полученных главных компонент с использованием средств библиотеки matplotlib, обозначая экземпляры разных классов с использованием разных цветовых маркеров;
3. Используя собственные значения, рассчитанные на этапе 1, вычислить потери, связанные с преобразованием по методу PCA. Сделать выводы;

Результат:










```
Размер выборки: (299, 13)

Пропуски по колонкам:
age                         0
anaemia                     0
creatinine_phosphokinase    0
diabetes                    0
ejection_fraction           0
high_blood_pressure         0
platelets                   0
serum_creatinine            0
serum_sodium                0
sex                         0
smoking                     0
time                        0
DEATH_EVENT                 0
dtype: int64
Пропусков нет — заполнение не требуется.
```

```
Собственные значения (по убыванию):
[1.66854625 1.5843945  1.27239806 1.11968295 1.03333917 0.99219419
 0.88632232 0.84812523 0.76658155 0.71018618 0.64617272 0.51232534]

Потери при преобразовании PCA:
  k = 2: сохранено 27.02% дисперсии, потери = 72.98%
  k = 3: сохранено 37.59% дисперсии, потери = 62.41%

Проверка через sklearn:
  k = 2: сохранено 27.02%, потери = 72.98%
  k = 3: сохранено 37.59%, потери = 62.41%
```

Обе реализации метода главных компонент показали одинаковые значения объяснённой дисперсии и потерь, что говорит о правильности ручного алгоритма. Две компоненты сохраняют около 27 % информации, потери составляют примерно 73 %, а три компоненты – 37 % информации и примерно 63 % потерь. Большие потери говорят о слабой связи признаков и «размазанности» дисперсии по многим осям — значит, PCA плохо подходит для сжатия и визуализации этих данных.

Вывод: в данной лабораторной работе я научилась применять метод PCA для осуществления визуализации данных.