Министерство образования Республики Беларусь
Учреждение образования
«Брестский государственный технический университет»
Кафедра ИИТ

Лабораторная работа №3

По дисциплине: «Интеллектуальный анализ данных»

Тема: «Предобучение нейронных сетей с использованием автоэнкодерного подхода»

Выполнил:
Студент 4 курса
Группы ИИ-25
Трошин И.Д.
Проверила:
Андренко К.В.

Брест 2026

Цель работы: научиться осуществлять предобучение нейронных сетей с помощью автоэнкодерного подхода.

Общее задание

1. Взять за основу любую сверточную или полносвязную архитектуру с количеством слоев более 3. Осуществить ее обучение (без предобучения) в соответствии с вариантом задания. Получить оценку эффективности модели, используя метрики, специфичные для решаемой задачи (например, MAPE – для регрессионной задачи или F1/Confusion matrix для классификационной).

2. Выполнить обучение с предобучением, используя автоэнкодерный подход, алгоритм которого изложен в лекции. Условие останова (например, по количеству эпох) при обучении отдельных слоев с использованием автоэнкодера выбрать самостоятельно.

3. Сравнить результаты, полученные при обучении с/без предобучения, сделать выводы.

4. Выполните пункты 1-3 для датасетов из ЛР 2.

5. Оформить отчет по выполненной работе, загрузить исходный код и отчет в соответствующий репозиторий на github.

Вариант 13

№	Выборка	Тип задачи	Целевая переменная
13	https://archive.ics.uci.edu/dataset/863/maternal+health+risk	классификация	RiskLevel

Ход работы

Исходный файл имеет структуру:

Age	SystolicBP	DiastolicBP	BS	BodyTemp	HeartRate	RiskLevel
25	130	80	15	98	86	high risk
35	140	90	13	98	70	high risk
29	90	70	8	100	80	high risk
30	140	85	7	98	70	high risk

Выборка содержит 1014 записей и 6 числовых признаков: Age (возраст), SystolicBP и DiastolicBP (систолическое и диастолическое давление), BS (уровень сахара в крови), BodyTemp (температура тела), HeartRate (частота пульса). Целевая переменная RiskLevel принимает три значения: low risk, mid risk, high risk.

В исходных данных 562 строки являются дубликатами. Если оставить их, одинаковые объекты попадают одновременно в обучающую и тестовую выборки, и метрики оказываются завышенными. Поэтому дубликаты удалены, осталось 452 объекта.

Класс	До удаления дубликатов	После удаления дубликатов
low risk	406	234
mid risk	336	106
high risk	272	112
Всего	1014	452

Подготовка данных

Выборка делится на обучающую и тестовую в пропорции 80/20. Признаки масштабируются в диапазон [0, 1] (MinMaxScaler, параметры подбираются по обучающей выборке). Такой диапазон соответствует области значений сигмоиды, которая используется на выходе автоэнкодера.

Архитектура сети

Полносвязная сеть 6-32-32-16-3: три скрытых слоя с сигмоидной активацией и выходной слой на три класса (softmax входит в функцию ошибки CE). Инициализация весов: Xavier.

Обучение без предобучения

Сеть обучается целиком методом обратного распространения ошибки с функцией ошибки CE (cross-entropy).

Обучение с предобучением (автоэнкодерный подход)

Алгоритм:

1. Для первого скрытого слоя строится автоассоциативная сеть «вход – скрытый слой – вход». Она обучается с функцией ошибки MSE, после чего веса кодировщика фиксируются и переносятся в основную сеть.
2. Выход первого слоя подаётся на вход автоэнкодера для второго слоя, который обучается аналогично. Так предобучаются все три скрытых слоя.
3. Последний слой (16-3) обучается с учителем (CE) при замороженных предобученных слоях.
4. Вся сеть дообучается с учителем для точной настройки параметров.

Параметры экспериментов

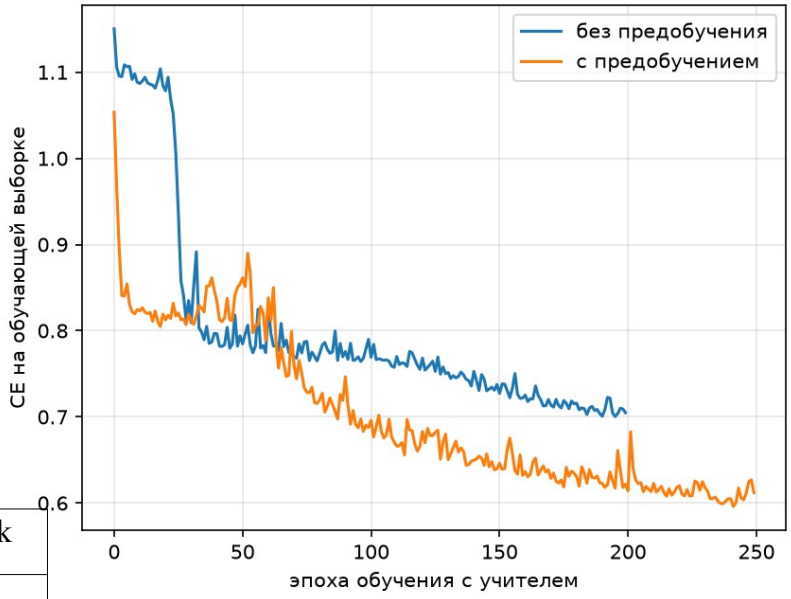
Параметр	Значение
Оптимизатор	SGD с моментом 0,9
Скорость обучения	0,1
Размер мини-батча	32
Эпох на один автоэнкодер (условие останова)	100

Эпох обучения только последнего слоя	50
Эпох дообучения всей сети (в обоих вариантах)	200

Метрики

- **Accuracy** — доля правильно классифицированных объектов.
- **Macro-F1** — среднее F1-мер по классам без учёта их размера. Метрика штрафует за пренебрежение редкими классами, в отличие от accuracy.
- **Матрица ошибок (confusion matrix)** — таблица, где строки соответствуют истинному классу, а столбцы предсказанному. Диагональ содержит верные ответы, остальные ячейки показывают, какие классы модель путает.

Результат



Сводные метрики

Модель	Accuracy	Macro-F1
Без предобучения	0,670	0,493
С предобучением	0,670	0,556

Без предобучения:

Истина \ Прогноз	low risk	mid risk	high risk
low risk	44	0	3
mid risk	15	0	6
high risk	6	0	17

С предобучением:

Истина \ Прогноз	low risk	mid risk	high risk
low risk	42	1	4
mid risk	12	3	6
high risk	3	4	16

С предобучением accuracy не изменилась (0,670), а macro-F1 выросла с 0,493 до 0,556: сеть начала распознавать класс mid risk (3 объекта из 21 против 0), который без предобучения полностью игнорировала. Платой стало небольшое снижение полноты классов low risk и high risk. Причина в том, что выборка мала (452 объекта), и несбалансирована.

Выполнение пунктов 1-3 для датасетов из ЛР 2 (Rice).

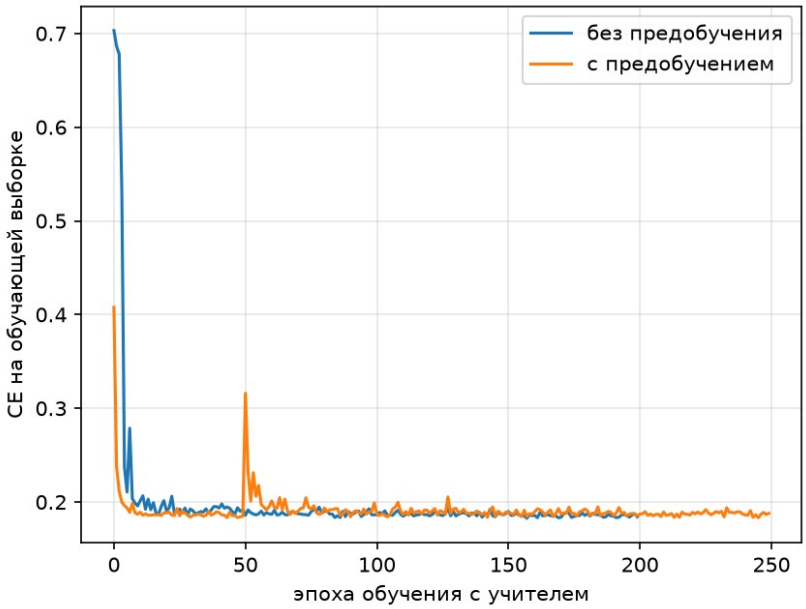
Выборка Rice (Cammeo и Osmancik) содержит 7 признаков: Area, Perimeter, Major_Axis_Length, Minor_Axis_Length, Eccentricity, Convex_Area, Extent. Целевая переменная Class принимает значения Cammeo (1630 объектов) и Osmancik (2180 объектов). Дубликатов нет.

Задача бинарная, класс Osmancik составляет около 57% выборки.

Подготовка данных, параметры и алгоритм те же, что в разделе 4, меняются только размеры входа и выхода: сеть 7-32-32-16-2. Разбиение 80/20.

Результат

Модель	Accuracy	Macro-F1
Без предобучения	0,924	0,923
С предобучением	0,925	0,923



Матрица ошибок без предобучения:

Истина \ Прогноз	Cammeo	Osmancik
Cammeo	305	21
Osmancik	37	399

Матрица ошибок с предобучением:

Истина \ Прогноз	Cammeo	Osmancik
Cammeo	292	34
Osmancik	23	413

Предобучение практически не изменило результат: accuracy 0,925 против 0,924, macro-F1 0,923 в обоих случаях (разница в один объект из 762). Изменилось только распределение ошибок между классами. Причина в том, что выборка большая (3048 обучающих объектов), а семь признаков хорошо разделяют классы, поэтому обычное обучение и так настраивает сеть достаточно хорошо, и предобучение здесь не нужно.

Вывод: научился осуществлять предобучение нейронных сетей с помощью автоэнкодерного подхода.